

The Trade-off of Existential Risk

A short policy brief

Jay Ballesteros

2026-05-20

This policy brief was written as part of the AI Policy Fundamentals Reading Group at the Existential Risk Laboratory (XLab), University of Chicago. The views expressed are the author's own and do not necessarily represent the position of the laboratory.

Overview

A pesar del potencial de la IA en acelerar el progreso, crecimiento exponencial en términos de GPD y la innovación y, de acuerdo con algunas personas, resolver todos los problemas de la humanidad (Amodei 2024), hoy la tecnología goza de poco apoyo público. Aunque las razones parten de la potencial pérdida de trabajo debido a la automatización y el riesgo y exposición de ciertas profesiones (Falk and Tsoukalas 2026), expertos acentúan que los riesgos pueden ser significativamente más graves – incluso existenciales.

Dinámicas como la carrera comercial de las empresas with the latest frontier models, el interés geopolítico de China y USA en dominar los avances y capacidades computacionales, el potencial de implementación de la tecnología en warfare decisions y la posibilidad de misalignment de los modelos, son factores que factibilizan más latente el riesgo existencial de la IA para la especie humana. (Yudkowsky 2026)

Dado el trade-off de extinción de la especie (algunos expertos estiman un 10% de posibilidad) es imperativo lograr un acuerdo global donde se prioricen tres factores: 1) estandarizar mecanismos de licencia, transparencia y evaluación de los modelos en términos de safety; 2) establecer mecanismos de no proliferación en chips y su tecnología subyacente; y 3) generar capacidad técnica en estados hegemónicos para asegurar la vigilancia de los mecanismos.

Findings

Jones (2024) considers an analogous question with respect to artificial intelligence. Suppose on one side that AI has incredible benefits, raising economic growth to 10 percent per year and thus doubling the average standard of living every 7 years. However, it comes with a one-time risk of killing everyone on the planet. How much risk would standard economic agents be willing to take in this case? (Jones 2024) ## Case study

Key considerations

La propuesta no es una apología a la intervención ni a la estatización de la tecnología, pero si al establecimiento de reglas que ayuden a reducir los riesgos existenciales inherentes a la IA.

Más de allá de mecanismos formales como mesas de diálogo, incorporación de la voz de las empresas en la discusión y reglas y establecimiento de steering committees, para vigilar su implementación, es necesario acelerar el diseño y piloto de reglas para desacelerar las dinámicas que son riesgos sistémicos.

Policy takeaways

About the Author

Jay Ballesteros is an MPP candidate at the Harris School of Public Policy, University of Chicago. He is a Fellow at the Existential Risk Laboratory (XLab).

References

- Amodei, Dario. 2024. “Machines of Loving Grace: How AI Could Transform the World for the Better.” October. <https://www.darioamodei.com/essay/machines-of-loving-grace>.
- Falk, Brett Hemenway, and Gerry Tsoukalas. 2026. *The AI Layoff Trap*. <https://arxiv.org/abs/2603.20617>.
- Jones, Charles I. 2024. “The AI Dilemma: Growth Versus Existential Risk.” *American Economic Review: Insights* 6 (4): 575–90. <https://doi.org/10.1257/aeri.20230570>.
- Yudkowsky, Eliezer. 2026. “Only Law Can Prevent Extinction.” April 13. <https://www.lesswrong.com/posts/5CfBDiQNg9upfipWk/only-law-can-prevent-extinction>.