

Slowing the AGI Race for Reducing Catastrophic Risk

Policy brief

Jay Ballesteros

2026-06-21

Overview

A pesar del potencial de la AGI para acelerar el progreso (Amodei 2024), hoy existe poco apoyo público a la aceleración de su desarrollo y la atención de la ciudadanía tiende más a su regulación por el potencial impacto en el mercado laboral (Stanford Institute for Human-Centered Artificial Intelligence 2026). Sin embargo, existe una preocupación que está ganando fuerza entre académicos y tomadores de decisiones: el riesgo existencial y catastrófico (Amodei 2026; Jones 2024; Bueno de Mesquita et al. 2026; California State Legislature 2026).

Las dinámicas de carrera comercial y tecnológica¹ dificultan la reducción de estos riesgos, pues empresas y gobiernos (entendámoslos como entes o firmas) tienen sus incentivos focalizados en la velocidad de despliegue en lugar de la seguridad de sus modelos (Bueno de Mesquita et al. 2026) y la desaceleración a través de la regulación es uno de los mecanismos que pueden ayudar a reducir dichos riesgos (Yudkowsky 2026).

Dada la dinámica de carrera que existe en torno a AGI, la seguridad de la IA adquiere la categoría de un problema de acción colectiva (Wikipedia contributors 2026), pues a pesar de que la decisión óptima está en tener despliegues seguros (con menor riesgo catastrófico y/o existencial), la competencia motiva a que las firmas prioricen el cómputo existente para escalar las capacidades de sus modelos (y así incrementar su probabilidad de ganar la carrera) en lugar de destinar una

mayor proporción a experimentos de seguridad (Bueno de Mesquita et al. 2026).

Las propuestas para regular el sector, se centran principalmente en mecanismos de compromiso, disuación y regulación de recursos. En algunos casos, con similitudes a la gobernanza nuclear. Ejemplos de esto están en el compromiso de desaceleración de las firmas, no-proliferación de chips de última generación, mayor ratio de cómputo dirigido a seguridad en lugar de desarrollo y despliegue, barreras de acceso al mercado de desarrollo de IA y cooperación global para la mitigación de riesgos.

“Actors can improve their chance of winning only by accepting a higher probability of a catastrophic outcome (Bueno de Mesquita et al. 2026)”

Findings

Los riesgos catastróficos y existenciales residen en la capacidad de los modelos de IA en mentir y convencer a los humanos, pero que culmina en dichos modelos adquiriendo tendencias de búsqueda de poder (Turner et al. 2023). No obstante, más allá de los forecasts de iniciativas como AI 2027 (Kokotajlo et al. 2025) las iniciativas de policy se centran en reducir el riesgo de llegar a escenarios de naturaleza catastrófica mientras el progreso basado en los modelos sigue siendo una posibilidad.

Antes de pasar a los riesgos puntuales, vale la pena considerar los *trade-offs*. Mientras que Jones (2026) señala que entre un 25% y 33% de riesgo de que una AGI extinga la raza humana, vale la pena a cambio de 10% de crecimiento anual y una reducción de la mortalidad al 50%

¹Anthropic y OpenAI compitiendo por alcanzar AGI y próximos a lanzar IPO (a junio de 2026) para financiar mayor capacidad de cómputo. Asimismo, la tensión geopolítica entre USA y China por acceder a chips de última generación y modelos de frontera.

(por avances en la medicina) (Jones 2026). Por otro lado, Bueno de Mesquita (2026) formaliza en un modelo que alcanzar la AGI, en una dinámica de carrera donde las firmas priorizan despliegue y desarrollo vs seguridad, puede tener un valor esperado negativo (Bueno de Mesquita et al. 2026).

Actualmente el mundo está subinvertiendo por un factor de 30 o más en AI safety. Jones (2026) que si la inversión ascendiera a 0.33% del PIB de USA (o \$100 mil millones de USD), el riesgo podría disminuir lo suficiente para pasar un análisis de costo-beneficio.

Case study

Key considerations

Policy takeaways

About the Author

Jay Ballesteros is an MPP candidate at the Harris School of Public Policy, University of Chicago. He is a Fellow at the Existential Risk Laboratory (XLab).

This policy brief was written as part of the AI Policy Fundamentals Reading Group at the Existential Risk Laboratory (XLab), University of Chicago. The views expressed are the author's own and do not necessarily represent the position of the laboratory.

References

- Amodei, Dario. 2024. "Machines of Loving Grace: How AI Could Transform the World for the Better." October. <https://www.darioamodei.com/essay/machines-of-loving-grace>.
- Amodei, Dario. 2026. "The Adolescence of Technology." January. <https://www.darioamodei.com/essay/the-adolescence-of-technology>.
- Bueno de Mesquita, Ethan, Wioletta Dziuda, and Mattias Polborn. 2026. *The AGI Race and Existential Risk*. Working Paper No. 35276. Working Paper Series. National Bureau of Economic Research. <https://doi.org/10.3386/w35276>.
- California State Legislature. 2026. *Senate Bill No. 53: Artificial Intelligence Models: Large Developers (Transparency in Frontier Artificial Intelligence Act)*. LegiScan. <https://legiscan.com/CA/text/SB53/id/3270002>.
- Jones, Charles I. 2026. *AI and Our Economic Future*. National Bureau of Economic Research.
- Jones, Charles I. 2024. "The AI Dilemma: Growth Versus Existential Risk." *American Economic Review: Insights* 6 (4): 575–90. <https://doi.org/10.1257/aeri.20230570>.
- Kokotajlo, Daniel, Eli Lifland, Thomas Larsen, and Romeo Dean. 2025. *AI 2027: A Detailed Scenario Forecast*. AI Futures Project. <https://ai-2027.com/>.
- Stanford Institute for Human-Centered Artificial Intelligence. 2026. *Artificial Intelligence Index Report 2026: Chapter 9: Public Opinion*. Report Chapter. Stanford University. https://hai.stanford.edu/assets/files/ai_index_report_2026_chapter_9_public_opinion.pdf.
- Turner, Alexander Matt, Logan Smith, Rohin Shah, Andrew Critch, and Prasad Tadepalli. 2023. *Optimal Policies Tend to Seek Power*. <https://arxiv.org/abs/1912.01683>.
- Wikipedia contributors. 2026. *Collective Action Problem — Wikipedia, the Free Encyclopedia*. https://en.wikipedia.org/wiki/Collective_action_problem.
- Yudkowsky, Eliezer. 2026. "Only Law Can Prevent Extinction." April 13. <https://www.lesswrong.com/posts/5CfBDiQNg9upfipWk/only-law-can-prevent-extinction>.